

Universidade Federal de Minas Gerais - UFMG

Aluna: Riscila Aparecida Lias Nicaio.

Matrícula: 2025 668486

Curso: Engenharia Elétrica / M (código 1451)

Disciplina: DIP EEE 950 Redes Neurais Artif. Teoria / Aplic.

Professores: Antônio de Pádua Braga / Frederico Coelho.

Texto Crítico sobre o Artigo: "Traffic Signal Control Optimization Based on Neural Network in the Framework of Model Predictive Control."

Zhang et al. (2024)

### 1. Introdução:

O texto foi selecionado por atender rigorosamente os critérios da atividade, destacando-se por apresentar uma metodologia inovadora no campo das Redes Neurais Artificiais, publicada em periódico revisado por pares, com ênfase no desenvolvimento e validação do modelo, e não apenas na validação prática. O artigo foi publicado em 2024 no periódico *Actuators* e propõe uma abordagem avançada que integra redes neurais convolucionais gráficas (GCNs) e aprendizado profundo por reforço (DRL) dentro de um framework de controle preditivo (MPC) para a opti-



miização dinâmica do controle de sinais de trânsito. Distanciando de trabalhos meramente aplicativos, a pesquisa detalha a arquitetura do modelo e o processo de treinamento, focando na captura precisa das dinâmicas espaço-temporais do tráfego e na adaptação contínua às variações do ambiente viário. Dessa forma, a metodologia contribui significativamente para o avanço das Redes Neurais Artificiais, entregando uma solução robusta, adaptativa e alinhada aos desafios reais do gerenciamento urbano do tráfego.

## 2. Metodologia e Resultados.

A metodologia apresentada no artigo baseia-se em uma rede convolucional gráfica dinâmica que captura as correlações espaciais e temporais do fluxo de veículos. Utiliza-se a convolução espectral para transformar as características dos nós no domínio espectral, aplicando filtros para extrair padrões complexos antes de retornar ao domínio espacial. Para lidar com a dinâmica temporal do tráfego, o modelo incorpora unidades recorrentes com portas (GRU), que controlam a retenção e o descar-



te de informações temporais, superando limitações das RNNs tradicionais.

Reconhecendo que as relações entre nós da rede viária são mutáveis, o modelo atualiza em tempo real a matriz de adjacência através de um módulo de fusão de matrizes de correlação, garantindo maior fidelidade à topologia do tráfego. Para o controle adaptativo, aplica-se o algoritmo Deep Q-Network (DQN), que seleciona faixas semafóricas a partir do estado do ambiente, buscando minimizar o tempo de espera cumulativo dos veículos. O espaço de estados é discretizado em 80 unidades (ou seja, 80 configurações distintas que o agente pode perceber), representando a ocupação das faixas, e o agente escolhe entre quatro ações pré-definidas que abrangem as principais fases para movimentos nas direções Norte-Sul e Leste-Oeste. A função de recompensa é normalizada para favorecer políticas que otimizem o fluxo veicular. O aprendizado utiliza Q-learning com uma rede neural de cinco camadas ocultas e



experiência replay para garantir robustez.

As simulações no SUMO usando dados reais e cenários sintéticos, mostram que o método MPC-NN supera os métodos (FT) e auto-organizado (SOTL), aumentando a velocidade média e reduzindo significativamente o comprimento das filas tanto em baixo quanto em alto fluxo de tráfego.

### 3. Conclusões e Perspectivas

O estudo mostra que integrar GCNs com aprendizado por reforço em um modelo de controle preditivo oferece solução eficiente e adaptativa para otimizar sinais de trânsito, embora ajustes e melhorias em escalabilidade e tempo real sejam necessários; a principal contribuição é avançar o estado da arte em redes neurais aplicadas ao controle de tráfego, superando métodos tradicionais. Futuros trabalhos devem focar em otimização computacional para tempo real, integração distribuída e coordenação multimodal, ampliando a aplicabilidade em larga escala.